# Büyük Dil Modellerinde Çok Disiplinli Halüsinasyon Tespiti ve Otomatik Değerlendirme Aracı Geliştirilmesi

Esad Abdullah Kösedağ
Yazılım Mühendisliği
*Fırat Üniversitesi*
Elazığ,Türkiye
240542017@firat.edu.tr

Sevda Tuba Ehlibeyt
Yazılım Mühendisliği
*Fırat Üniversitesi*
Elazığ,Türkiye
240541005@firat.edu.tr

Ahmet Ali Yılmaz
Yazılım Mühendisliği
*Fırat Üniversitesi*
Elazığ,Türkiye
240541051@firat.edu.tr

Mehmet Sönmez
Yazılım Mühendisliği
*Fırat Üniversitesi*
Elazığ,Türkiye
240542011@firat.edu.tr

***Abstract*— Bu çalışma, Büyük Dil Modellerinin (LLM) ürettiği gerçek dışı bilgilerin (halüsinasyonlar) sistematik olarak tespitini, analizini ve sınıflandırmasını amaçlamaktadır. Araştırma kapsamında; Llama-3, Mistral ve Phi-3 modellerinin felsefe, hukuk, matematik ve uluslararası standartlar gibi farklı disiplinlerdeki performansları karşılaştırmalı olarak incelenmektedir. Geliştirilmesi hedeflenen web tabanlı araç ile modellerin uydurma ve tutarsızlık hatalarının sınıflandırılması, elde edilen verilerle modellerin halüsinasyon eğilimlerinin ve güvenilirlik risklerinin raporlanması hedeflenmektedir.**

**Keywords—Büyük Dil Modelleri(LLM), Halüsinasyon Tespiti, Yazılım Test Araçları, Llama-3, Model Güvenilirliği.**

## I. INTRODUCTION

Günümüzde Büyük Dil Modelleri (LLM) eğitimden yazılıma, hukuktan sağlığa kadar pek çok alanda yaygın olarak kullanılmaktadır. Ancak bu modeller her ne kadar insan hayatını kolaylaştırıp pek çok alanda işimize yarasada bazen verdiği bilgiler doğru olmamasına rağmen doğruymuş gibi insanlara aktarılıp ikna edici bir dille kişiye sunulmaktadır, yani halüsinasyon görmektedirler. Bu durum, bazen yüksek doğruluk gerektiren hukuk, matematik, tıp, yazılım gibi bir çok alanda güvenilirlik sorununa yol açıp bu bilgilerin yanlış olarak yayılmasına yol açabilir.
Her ne kadar Llama-3, Mistral ve Phi-3 gibi modeller farklı alanlara sahip olsada hangi disiplinde ne kadar hata yaptıkları üzerine yapılan çalışmalar yetersizdir.
Biz bu çalışmayla; Llama-3, Mistral ve Phi-3 modellerinin farklı uzmanlık alanları olan felsefe, hukuk , matematik ve uluslararası standartlar gibi alanlardaki halüsinasyon oranlarını otomatik olarak ölçen, kıyaslayan ve sınıflandıran bir test aracı geliştirmeyi hedeflemekteyiz. Bu sayede kullanıcı hangi modelin hangi disiplinde daha doğru bilgi verdiğini yani ne kadar güvenilir olduğunu anlamasına yardımcı olmayı hedeflemekteyiz. Geliştirilecek olan otomasyon sayesinde manuel olan inceleme süreçlerini hızlandırarak daha objektif bir değerlendirme sunacaktır. Kısacası amaç ,kullanıcıların LLM teknolojilerini daha bilinçli ve güvenli bir şekilde kullanmalarına katkı sağlamak.

## II. RELATED WORKS

Büyük dil modellerinde halüsinasyon, son yıllarda merkezi bir araştırma konusu haline gelmiştir. Alansari ve Luqman [1], veri toplamadan çıkarıma kadar tüm LLM geliştirme yaşam döngüsü boyunca halüsinasyon türlerinin kapsamlı bir taksonomisini sunmakta ve tespit ve azaltma yaklaşımlarını sistematik olarak incelemektedir. Araştırmaları, temel nedenleri sınıflandırmakta ve açık zorlukları belirleyerek, sonraki ampirik çalışmalar için temel bir referans sunmaktadır.
Bang ve ark. [2], LLM'lerde hem dışsal hem de içsel halüsinasyonları değerlendirmek için özel olarak tasarlanmış bir kıyaslama aracı olan HalluLens'i tanıtmıştır. Bu çalışmanın önemli bir katkısı, model çıktısının eğitim verilerinden sapması ile çıktının içsel olarak tutarsız olması arasındaki ayrımdır. HalluLens, veri sızıntısını önlemek için dinamik test seti oluşturmayı içerir ve kıyaslama tabanlı değerlendirmelerde önemli bir tekrarlanabilirlik sorununu ele alır. Bununla birlikte, değerlendirmesi kontrollü bir kıyaslama ortamında kalmakta ve karşılaştırmalı bir çerçevede çeşitli bilgi alanlarında model davranışını değerlendirmemektedir.
Massenon ve ark. [3], yapay zeka destekli mobil uygulamalardan üç milyondan fazla kullanıcı yorumunu analiz eden büyük ölçekli bir ampirik çalışma sunmaktadır. Anahtar kelime filtreleme, NMF konu modelleme ve VADER duygu analizini birleştiren karma yöntem yaklaşımını kullanan yazarlar, yedi halüsinasyon türünden oluşan kullanıcı merkezli bir taksonomi geliştirdiler. Bulguları, Gerçek Yanlışlığın kullanıcı tarafından bildirilen halüsinasyon örneklerinin %38'ini oluşturduğunu, Uydurma Bilgi ve Anlamsız Çıktının birlikte ek %40'ını oluşturduğunu göstermektedir. Bu çalışma, gerçek dünya, kullanıcı merkezli bakış açısıyla dikkat çekmektedir; ancak, referans kaynaklarına karşı otomatik gerçek doğrulama yerine dolaylı kullanıcı raporlarına dayanmaktadır.
Bu çalışmalar her ne kadar bu konularda bilenen boşluklara değinselerde çok-disiplinli şekilde doğrulanabilir kaynaklarla

yapılmış bir benchmark çerçevesi sunmamaktadırlar. Bu projenin net ve kesin amacı Llama-3, Mistral, Phi-3 modellerini alıntı hataları, matematiksel denklem çözümlerinde manipülasyona uğrama, uluslar arası standartları gerçek hayat senaryoları ile teste tabi tutma gibi çok-disiplinli ve doğrulanabilir referansları olan alanlarda bu eksikliği tamamlayarak geniş bir benchmark çerçevesi sunmaktır

## REFERENCES


[1] A. Alansari and H. Luqman, "Large Language Models Hallucination: A Comprehensive Survey," arXiv:2510.06265, Oct. 2025.

[2] Y. Bang, Z. Ji, A. Schelten, A. Hartshorn, T. Fowler, C. Zhang, N. Cancedda, and P. Fung, "HalluLens: LLM Hallucination Benchmark," in *Proc. 63rd Annual Meeting of the Association for Computational Linguistics (ACL)*, Vienna, Austria, Jul. 2025, pp. 24128–24156.

[3] R. Massenon, I. Gambo, J. A. Khan, C. Agbonkhese, and A. Alwadain, "'My AI is Lying to Me': User-reported LLM hallucinations in AI mobile apps reviews," *Scientific Reports*, vol. 15, Art. no. 30397, Aug. 2025.


XXX-X-XXXX-XXXX-X/XX/$XX.00 ©20XX IEEE